Сравнительный анализ архитектур U-Net для задачи сегментации линий сетки в документах

Фролова Анастасия Ивановна
Университет Иннополис
Email: a.frolova@innopolis.university

Аннотация—В работе рассматривается задача автоматической детекции линий сетки на изображениях бумажных схем для вышивки крестиком. Предлагается подход, основанный на семантической сегментации с использованием двух архитектур: классической U-Net и ResU-Net. Проводится сравнительный анализ данных моделей, оценивается их способность выделять границы ячеек в условиях зашумлённых изображений. Эксперименты на датасете из 70 размеченных схем показывают, что обе модели успешно детектируют линии сетки, однако качество существенно зависит от сложности изображения. Средний Dice coefficient составил 0.415 для U-Net и 0.548 для ResU-Net, что свидетельствует об эффективности архитектур.

I. Введение

Оцифровка бумажных схем для вышивки крестиком — трудоёмкий и подверженный ошибкам процесс. Рукодельницы вынуждены вручную переносить символы и цвета в цифровой формат, что занимает большое количество времени. Существующие OCR-системы не справляются со спецификой схем: цветной фон, перекрытие символов, деформации бумаги. В данной работе мы рассматриваем задачу детекции линий сетки как первый и ключевой этап автоматической оцифровки.

Основной вклад работы:

1) Сравнительный анализ двух архитектур: U-Net и ResU-Net для сегментации линий сетки.
2) Разработка единого алгоритма постобработки, включающего HoughLinesP, адаптивную группировку и восстановление пропущенных линий.
3) Создание датасета из 70 размеченных схем вышивки.
4) Количественная оценка качества работы моделей по метрикам IoU, Dice, Precision, Recall.

II. Обзор литературы

Задача детекции линий сетки может быть сведена к бинарной семантической сегментации, где модель классифицирует каждый пиксель как принадлежащий линии или фону.

Архитектура U-Net, предложенная Роннебергером [1], стала стандартом в задачах сегментации благодаря симметричной структуре кодер-декодер и пропускным соединениям, позволяющим сохранять мелкие детали.

В обзоре [2] представлен анализ современных методов детекции таблиц в документах. Авторы отмечают, что свёрточные нейронные сети, в частности архитектура U-Net, демонстрируют высокую эффективность при сегментации табличных границ. Поскольку схемы вышивки представляют собой регулярную структуру, аналогичную таблицам, методы, разработанные для извлечения таблиц, могут быть адаптированы для детекции линий сетки.

В работе [3] предложена архитектура ResU-Net++, в которой остаточные блоки позволяют стабилизировать градиенты и улучшить выделение тонких границ объектов. Полученные в настоящем исследовании результаты согласуются с этим выводом: применение ResU-Net обеспечило прирост Recall на 43% по сравнению с классическим U-Net, что подтверждает эффективность остаточных соединений при детекции линий сетки.

В работе [4] показано, что остаточные блоки улучшают обучение глубоких сетей. На основе этого построен ResU-Net, где Residual Block заменяют стандартные свёртки в кодере.

Классические методы детекции линий (Canny, Hough) требуют ручной настройки параметров под каждое изображение [5] и неэффективны при наличии шума. В данной работе они используются только как этап постобработки нейросетевых масок.

III. Методология

A. Постановка задачи

Пусть I — исходное изображение схемы размером $H \times W$. Необходимо построить бинарную маску M, где $M_{i,j} = 1$ для пикселей, принадлежащих линиям сетки, и $M_{i,j} = 0$ для фона. На основе маски восстанавливаются координаты горизонтальных и вертикальных линий, после чего определяется регулярная сетка и для каждой ячейки вычисляется доминирующий цвет.

B. Архитектуры моделей

1) U-Net (базовая архитектура): Классический U-Net состоит из:

- Энкодер: последовательность блоков DoubleConv (Conv3x3 + BN + ReLU) с последующим MaxPool2d. Каналы: $64 \to 128 \to 256 \to 512$.
- Боттлнек: DoubleConv(512, 1024).
- Декодер: повышение разрешения с помощью билинейной интерполяции и DoubleConv, объединение с пропускными связями.

2) ResU-Net: Модификация U-Net, в которой в энкодере и боттлнеке стандартные свертки заменены на Residual Blocks с shortcut-соединением. Это позволяет стабилизировать градиенты и обучать более глубокие модели без переобучения.

C. Алгоритм постобработки

Единый алгоритм постобработки применяется к бинарным маскам, полученным от обеих моделей:

1) Детекция линий: HoughLinesP с параметрами threshold=50, minLineLength = min(H,W)//4, maxLineGap=20.
2) Фильтрация: по углу (горизонтальные: $|angle| < 20°$, вертикальные: $70° < angle < 110°$) и по длине (не менее 30% ширины/высоты).
3) Группировка: объединение близких линий с усреднением.
4) Восстановление пропущенных линий: если разрыв между последовательными линиями превышает медианный шаг в 1.5 раза, добавляются промежуточные линии.
5) Выравнивание ячеек: если расстояние между линиями превышает медианный шаг в 1.8 раза, добавляются недостающие линии.

D. Определение цвета ячеек

Для каждой ячейки, ограниченной двумя горизонтальными и двумя вертикальными линиями:

1) Вырезается область $[y_1 : y_2, x_1 : x_2]$.
2) От краёв отступается 5 пикселей для исключения границ.
3) Вычисляется среднее арифметическое RGB-значений для определения доминирующего цвета.

Результат представляется в виде RGB-матрицы размера $rows \times cols$, где каждый элемент — вектор (R, G, B).

E. Метрики оценки

Для сравнения качества использовались:

- IoU (Intersection over Union): $\frac{TP}{TP+FP+FN}$.
- Dice coefficient: $\frac{2TP}{2TP+FP+FN}$.
- Precision: $\frac{TP}{TP+FP}$.
- Recall: $\frac{TP}{TP+FN}$.

IV. Экспериментальная часть

A. Датасет

Собран датасет из 70 изображений бумажных схем для вышивки крестиком:

- Тренировочная выборка: 56 схем.
- Валидационная выборка: 14 схем.

Каждое изображение размечено вручную: создана бинарная маска линий сетки. Имена масок соответствуют формату ‘имямask.png‘.

B. Параметры обучения

Обучение проводилось на GPU NVIDIA Tesla T4 (Google Colab):

- Размер входного изображения: 256×256 (для ускорения).
- Batch size: 4.
- Оптимизатор: Adam, learning rate $= 1 \times 10^{-4}$.
- Функция потерь: BCEWithLogitsLoss.
- Количество эпох: 30.
- Early stopping: patience=5.
- В работе не использовалась аугментация данных, что позволяет оценить «чистую» эффективность архитектур без искусственного расширения выборки.

C. Результаты

В таблице I представлены результаты сравнительного анализа на тестовой выборке.

Таблица I
Сравнение метрик U-Net и ResU-Net

Изображение	Модель	IoU	Dice	Precision	Recall
image1	U-Net	0.099	0.180	0.915	0.100
	ResU-Net	0.222	0.363	0.917	0.226
image2	U-Net	0.388	0.559	0.913	0.403
	ResU-Net	0.459	0.630	0.893	0.486
image3	U-Net	0.339	0.506	0.895	0.353
	ResU-Net	0.482	0.650	0.893	0.511
Среднее	U-Net	0.275	0.415	0.908	0.285
	ResU-Net	0.388	0.548	0.901	0.408

На рисунке 1 представлены примеры визуализации работы моделей.

D. Анализ результатов

Экспериментальное сравнение показало, что обе архитектуры успешно справляются с задачей детекции линий сетки. На тестовой выборке средний Dice coefficient составил 0.415 для U-Net и 0.548 для ResU-Net, средний IoU — 0.275 и 0.388 соответственно.

Наибольшая точность достигнута на изображениях с хорошо видимыми линиями сетки, контрастирующими с рисунком, наименьшая — на сильно зашумлённых схемах.

ResU-Net показал более высокие результаты по всем метрикам: Dice на 32% выше, IoU на 41% выше, Recall на 43% выше. Это свидетельствует о преимуществе остаточных блоков для задачи детекции линий сетки.

Основные источники ошибок:

- Потеря крайних линий сетки из-за отсутствия контекста у модели.
- Ошибочное добавление линий на фрагментах с высокой плотностью символов.
- Линии, нетипично отрисованные на схемах (пунктирные, цветные, тонкие, отсутствующие).
- Изображение сливается с линиями сетки.

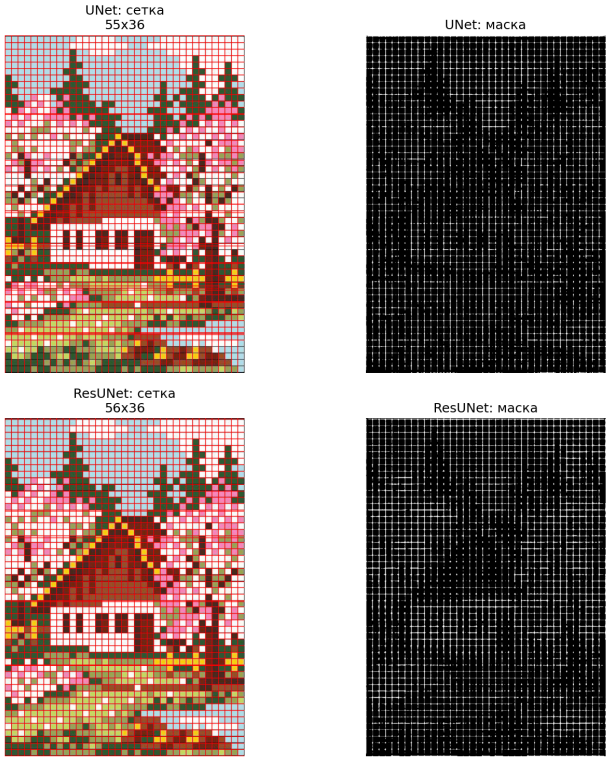

Рис. 1. Пример работы: исходное изображение с определенной сеткой; маска, предсказанная моделью

V. Заключение

В работе проведён сравнительный анализ двух архитектур — U-Net и ResU-Net — для задачи сегментации линий сетки на изображениях схем вышивки.

1) Собран и размечен датасет из 70 изображений бумажных схем.
2) Реализованы и обучены две архитектуры; ResU-Net показал более высокие результаты по метрикам Dice (+32%), IoU (+41%) и Recall (+43%).
3) Разработан единый алгоритм постобработки, позволяющий преобразовать предсказанные маски в регулярную сетку и получить RGB-матрицу цветов ячеек.
4) Установлено, что качество детекции критически зависит от контраста и чёткости линий исходной схемы.

Перспективы дальнейших исследований включают увеличение датасета с целью обучения на различных вариантах сетки, распознавание символов внутри ячеек и разработку графического редактора для ручной коррекции.

Список литературы

[1] O. Ronneberger, P. Fischer, and T. Brox, “U-net: Convolutional networks for biomedical image segmentation,” in International Conference on Medical Image Computing and Computer-Assisted Intervention (MICCAI), 2015.

[2] S. Khan et al., “Deep learning for table detection and structure recognition: A survey,” arXiv preprint arXiv:2211.08469, 2022.

[3] D. Jha et al., “Resu-net++: An advanced residual u-net for medical image segmentation,” IEEE Transactions on Medical Imaging, 2022.

[4] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016, pp. 770–778.

[5] G. Bradski, “The opencv library,” Dr. Dobb’s Journal of Software Tools, 2000.